

Aspecto	K-Means	Clustering Jerárquico	DBSCAN
Definición	Algoritmo basado en centroides que divide los datos en K grupos.	Método que construye una jerarquía de grupos mediante fusiones o divisiones sucesivas.	Algoritmo basado en densidad que agrupa puntos cercanos y marca ruido.
Funcionamiento general	Asigna puntos al centroide más cercano y recalcula centroides hasta converger.	Genera un dendrograma que muestra cómo se agrupan los datos paso a paso.	Expande clusters a partir de puntos densos, conectando vecinos dentro de un radio (eps).
Parámetros principales	Número de clusters (K).	Método de enlace (single, complete, average).	eps (radio de vecindad), min_samples (mínimo de puntos para formar cluster).
Ventajas	Simple, rápido, fácil de implementar.	No requiere definir K al inicio, muestra jerarquía completa.	Detecta ruido y clusters de forma arbitraria, no necesita K.
Desventajas	Sensible a la elección de K y a outliers; asume clusters circulares.	Computacionalmente costoso en grandes datasets; sensible al método de enlace.	Sensible a parámetros eps y min_samples; puede fallar si densidad varía mucho.
Manejo de ruido	No maneja ruido, todos los puntos se asignan a un cluster.	No maneja ruido explícitamente.	Sí, etiqueta puntos como ruido si no cumplen densidad mínima.

Necesidad de definir número de grupos	Sí, se debe indicar K desde el inicio.	No, se puede cortar el dendrograma en cualquier nivel.	No, los clusters emergen de la densidad.
Casos de uso	Segmentación de clientes, agrupamiento rápido en datasets grandes.	Análisis exploratorio, visualización de jerarquías, biología (taxonomías).	Detección de anomalías, geolocalización, clusters con formas irregulares.

Cuestionario.

¿Cuál método es más fácil de entender?

K-Means, porque su lógica de centroides es sencilla y directa.

¿Cuál método requiere indicar el número de grupos desde el inicio?

K-Means (se debe definir K).

¿Cuál método puede detectar ruido o datos atípicos?

DBSCAN, porque etiqueta puntos como ruido.

¿Cuál método usarías para segmentar clientes de una tienda?

K-Means, ya que es rápido y funciona bien con datos de clientes (edad, ingresos, hábitos).

¿Cuál usarías si los grupos no tienen forma circular?

DBSCAN, porque detecta clusters con formas arbitrarias.

¿Qué podría pasar si eliges mal el valor de K en K-Means?

Los clusters pueden quedar mal definidos: demasiado pocos (agrupaciones muy generales) o demasiados (clusters irrelevantes).

¿Qué representa un dendrograma en clustering jerárquico?

Un árbol de fusiones que muestra cómo los datos se agrupan progresivamente, permitiendo elegir el nivel de corte.

¿Qué representan eps y min_samples en DBSCAN?

eps: radio máximo para considerar vecinos.

min_samples: número mínimo de puntos dentro de ese radio para formar un cluster.

Conclusiones:

el método más recomendable es K-Means porque:

Es fácil de implementar y entender.

Permite dividir clientes en grupos claros.

Es eficiente en grandes volúmenes de datos.